Aprendizaje Federado

Extensiones de Machine Learning

Ginés Carrillo Ibáñez

Yago Ibarrola Lapeña

Aarón Palomar Peña

Universidad de Murcia
Facultad de Informática

Curso 2025/2026

Contenidos

1 Sesión 1 **2**
1.1 FL centralizado 2
1.2 FL descentralizado 2

2 Sesión 2 **4**
2.1 Model poisoning 4

3 Sesión 3 **5**

1 Sesión 1

Para esta sesión, junto con la instalación de Nébula, se han realizado los siguientes cuatro experimentos sobre el entrenamiento de una CNN en el dataset CIFAR-10 de clasificación de imágenes. Se han realizado 10 rondas de entrenamiento en una única época, se han desplegado 4 nodos y las actualizaciones se han calculado usando FedAvg. Los experimentos realizados han sido:

- Entrenamiento centralizado con datos homogéneos (IID) y heterogéneos (non-IID) entre los nodos.
- Entrenamiento descentralizado con datos homogéneos (IID) y heterogéneos (non-IID) entre los nodos.

1.1 FL centralizado

Comparamos el entrenamiento IID y non-IID entre los nodos. En el caso non-IID, se utiliza una distribución de dirichlet con $\alpha = 0.1$. Se puede ver la comparación de ambos casos en la figura 1:

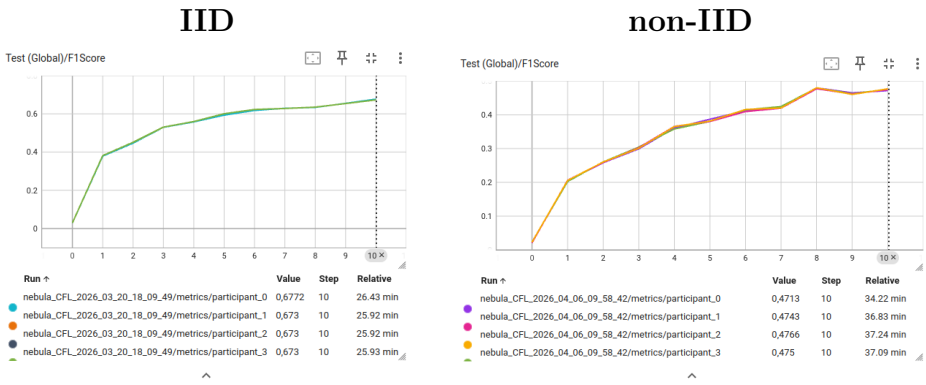

Figure 1: Comparación del entrenamiento centralizado con datos IID y non-IID.

Vemos que en el caso de datos homogéneos, el modelo converge más rápidamente y alcanza una mayor precisión, llegando en la ronda 10 a un F1-score de aproximadamente 0.65, mientras que en non-IID solo alcanza un F1-score de 0.47. Esto tiene sentido, ya que en el caso non-IID, cada nodo tiene una distribución de datos diferente, lo que dificulta la generalización del modelo global. Igualmente, en la ronda 3 IID ya alcanza un F1-score de 0.52, mientras que non-IID solo llega a 0.3.

1.2 FL descentralizado

En este caso, se ha realizado el mismo experimento pero con un entrenamiento descentralizado. Se muestran los resultados en la figura 2:

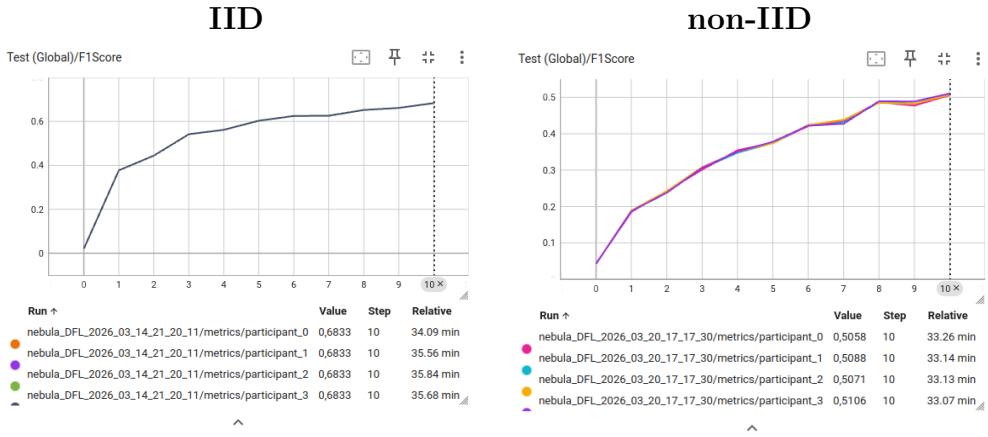

Figure 2: Comparación del entrenamiento descentralizado con datos IID y non-IID.

- Ronda 3: IID alcanza un F1-score de 0.5, mientras que non-IID solo llega a 0.3.
- Ronda 10: IID alcanza un F1-score de aproximadamente 0.67, mientras que non-IID solo alcanza un F1-score de 0.5.

En general, aunque CFL y DFL muestran resultados similares en términos de rendimiento (F1-score), presentan diferencias importantes a nivel de arquitectura. CFL destaca por su simplicidad y menor sobrecarga de red y recursos, pero introduce un punto único de fallo y posibles cuellos de botella en federaciones grandes. Por otro lado, DFL ofrece mayor resiliencia frente a fallos y ataques, a costa de una mayor complejidad en la gestión de modelos, sincronización para la agregación y comunicaciones entre nodos.

AÑADIR MATRICES

2 Sesión 2

Para esta sesión, se ha utilizado de nuevo la configuracion de entrenamiento de DFL non-IID de la sesión anterior. Se han realizado con ella los siguientes experimentos:

- Ataque de *model poisoning* con 10% de ruido gaussiano.
- Ataque de *label flipping* con 80% de muestras envenenadas.

Para cada uno de los ataques, compararemos con un 20% y un 50% de clientes maliciosos.

2.1 Model poisoning

En este ataque, los clientes maliciosos añaden ruido gaussiano a sus modelos locales antes de enviarlos al servidor.

3 Sesión 3

Para esta sesión, se ha utilizado de nuevo la configuración de entrenamiento DFL non-IID con un nodo malicioso realizando model poisoning de la sesión anterior. Se han realizado los siguientes experimentos:

- Agregación de de modelos usando trimmed mean.
- Agregación de modelos usando Krum.